

PROJEKT DATA SCIENCE

Analiza Jakości Powietrza dla Miasta Poznań

~ Porównanie modeli predykcyjnych Linear Regression oraz CatBoost ~

Autor: Jerzy Marcin Urbański

Cel projektu

Głównym celem projektu jest porównanie jakości predykcji oraz skuteczności dwóch modeli uczenia maszynowego nadzorowanego:

- **Linear Regression**
- **CatBoost Regressor**

Modele zostaną wytrenowane na przygotowanym zbiorze danych, a następnie ocenione przy użyciu odpowiednich metryk regresyjnych.

Analiza wyników pozwoli:

- określić dokładność obu modeli,
 - porównać ich zdolność do generalizacji,
 - wskazać model zapewniający lepsze prognozy jakości powietrza,
 - ocenić wpływ zastosowanej metody na końcową jakość predykcji.
-

Źródła danych

- Główny Inspektorat Ochrony Środowiska - <https://powietrze.gios.gov.pl/pjp/archiw>
 - ECMWF Copernicus Climate Change Service - <https://era5downloader.org/>
-

Plan realizacji

1. Wczytanie i wstępne przygotowanie danych.

- Wczytanie danych surowych
- Wstępna obróbka danych surowych
- Utworzenie wspólnego DataFrame MAIN
- Walidacja, weryfikacja struktury i statystyka opisowa MAIN

2. Diagnostyka / EDA / Agregacja

- Sprawdzenie duplikatów
- Sprawdzenie brakujących wartości
- EDA + Raport porfilowy
- Analiza Skośności
- Analizy Outlierów
- Badanie Korelacji

3. Transformacja Danych

- Feature engening
- Preprocessing dla Linear Regression

4. Budowa modeli + metryki

- Linear Regression
- CatBoost Regressor

5. Porównanie wyników

- Analiza błędów
- Interpretacja rezultatów
- Wnioski końcowe

Oczekiwany rezultat

Projekt ma na celu określenie, który z badanych modeli lepiej radzi sobie z prognozowaniem jakości powietrza na podstawie czteroletnich danych meteorologicznych oraz jakie korzyści daje zastosowanie bardziej zaawansowanych metod uczenia maszynowego w porównaniu z klasyczną regresją liniową.

.....

Modele ML - Opis i Teoria

1. Linear Regression

Regresja liniowa (Linear Regression) jest jednym z podstawowych algorytmów uczenia nadzorowanego (Supervised Learning), wykorzystywanym do modelowania zależności pomiędzy zmienną zależną (zmienną objaśnianą) a jedną lub wieloma zmiennymi niezależnymi (zmiennymi objaśniającymi). Głównym celem modelu jest znalezienie takiej funkcji liniowej, która w możliwie najlepszy sposób opisuje zależność występującą w danych oraz pozwala przewidywać wartości zmiennej docelowej dla nowych obserwacji. W przypadku regresji wielowymiarowej model można zapisać w postaci:

$$y = aX + b$$

gdzie:

- y - wektor cech zależnych (target)
- X - Macierz cech (features)
- a - wektor współczynników regresji
- b - wektor błędów

2. CatBoost Regression

CatBoost Regression jest algorytmem uczenia nadzorowanego przeznaczonym do przewidywania regresji, czyli wartości liczbowych. Model należy do rodziny algorytmów Gradient Boosting Decision Trees. CatBoost buduje wiele drzew decyzyjnych sekwencyjnie, gdzie każde kolejne drzewo uczy się na błędach popełnionych przez poprzednie drzewa. Dzięki temu model stopniowo poprawia jakość predykcji i jest w stanie uchwycić złożone, nieliniowe zależności występujące w danych.

Zasada Działania

CatBoost wykorzystuje technikę *Gradient Boostingu*, które polega na budowaniu zespołu wielu słabych modeli (drzew decyzyjnych). Każde nowe drzewo nie przewiduje wartości docelowej od początku, lecz stara się skorygować błąd poprzedniego modelu.

Proces działania:

1. Pierwsze drzewo
2. Model wykonuje predykcję na jego podstawie.
3. Obliczane są błędy predykcji (reszty)
4. Budowane jest kolejne drzewo uczące się tych błędów i minimalizowaniu funkcji straty.
5. Predykcje nowego drzewa są dodawane do poprzednich wyników.
6. Proces jest powtarzany, aż do osiągnięcia zadanej liczby drzew lub spełnienia kryterium zatrzymania.

Metryki Walidacyjne

1. MAE

Średni błąd bezwzględny określa przeciętna wartość odchylenia prognozy od wartości rzeczywistej obserwacji. Dla MAE idealnym wynikiem jest "0", im niższa wartość MAE, tym lepsza jakość predykcji. Metryka jest odporna na pojedyncze wartości odstające (outliery). Stabilna i podawana w jednostkach danych, co ułatwia interpretację. Należy ją stosować, gdy wszystkie błędy są równie ważne.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

gdzie:

- n – liczba obserwacji,
- y_i – rzeczywista wartość dla i -tej obserwacji,
- $\hat{y}_i$ – wartość przewidywana przez model dla i -tej obserwacji,

2. MSE

Średni błąd kwadratowy mierzy średnią wartość kwadratów błędów predykcji. MSE silnie karze duże błędy, poprzez podniesienie do kwadratu. Zaletą tej metryki jest to, że uwzględnia wpływ dużych odchyleń i przydaje się do optymalizacji modeli.

$$MAE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

gdzie:

- n – liczba obserwacji,
- y_i – rzeczywista wartość dla i -tej obserwacji,
- $\hat{y}_i$ – wartość przewidywana przez model dla i -tej obserwacji,

3. RMSE

Pierwiastek średniego błędu kwadratowego (Root Mean Squared Error) informuje o przeciętnym błędzie predykcji. Różni się od MAE tym, że duże błędy mają większy wpływ na tę metrykę i są bardziej zauważalne niż przy wynikach MAE.

$$MAE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

gdzie:

- n – liczba obserwacji,

- y_i – rzeczywista wartość dla i-tej obserwacji,
- $\hat{y}_i$ – wartość przewidywana przez model dla i-tej obserwacji,

4. R2

Współczynnik determinacji określa jaka część wariancji targetu wyjaśnia model. R2 na poziomie 1 to idealne dopasowanie, a R2 równe 0 model nie wyjaśnia lepiej zmienności danych niż średnia. Zaletą tej metryki jest czytelność skuteczności i poprawności działania modelu i pozwala go szybko ocenić.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

gdzie:

- y_i – rzeczywista wartość zmiennej docelowej dla i-tej obserwacji
- $\hat{y}_i$ – wartość przewidywana przez model
- $\bar{y}$ – średnia wartość zmiennej docelowej
- n – liczba obserwacji



Importy Bibliotek wraz z ich opisem

Sekcja bibliotek ML

STEP 1. Wczytanie i wstępne przygotowanie surowych danych

[LOAD DATA + PREPROCESSING NA WSTĘPNYCH DANYCH]

Import danych z plików csv , ostateczne sprawdzenie oraz potrzebna agregacja do ostatecznej wersji.

1.1. TABELLE DANE POGODOWE - weather_pz

1.1.1. Import wszystkich plików do odpowiednich zmiennych

Unnamed: 0	time	latitude	longitude	number	step	surface	valid_time	u
0	2021-01-01 00:00:00	52.5	17.0	0	0 days	0.0	2021-01-01 00:00:00	-2.4223
1	2021-01-01 06:00:00	52.5	17.0	0	0 days	0.0	2021-01-01 06:00:00	-2.4073

1.1.1. Połączenie w jedno DataFrame

1.1.2. Agregacja danych do postaci uniwersalnego DataFrame

Obliczenie prędkości wiatru ze zmiennych u10 & v10 ze wzoru tj z równania pitagorasa

- zmienna u10 => prędkość wiatru zachodniego
- zmienna v10 => prędkość wiatru północnego

$$v_w = \sqrt{u_{10}^2 + v_{10}^2}$$

1.1.3. PODSUMOWANIE DANE POGOWE

OPIS ZMIENNYCH

Zmienna	Opis	Jednostka
'u10'	predkosc wiatru z kierunku	[m/s]
'v10'	prędkość wiatru z kierunku	[m/s]
'v_w'	rzeczywista prędkość wiatru	[m/s]
't2m'	temperatura powietrze 2m nad poziomem powierzchni	[Kelwin]
'b1h'	WYSOKOŚĆ WARSTWY GRANICZNEJ	[m]
'sp'	CIŚNIENIE	[Pa]
'tcc'	CAŁKOWITE ZACHMURZENIE	[0-1] [%]

1.2. TABELE CAŁKOWITE OPADY - total_precipitation

1.2.1. Import wszystkich plików do odpowiednich zmiennych

	Unnamed: 0	time	step	latitude	longitude	number	surface	valid_time	tp
0	0	2020-12-31 18:00:00	0 days 01:00:00	52.5	17.0	0	0.0	2020-12-31 19:00:00	NaN
1	1	2020-12-31 18:00:00	0 days 02:00:00	52.5	17.0	0	0.0	2020-12-31 20:00:00	NaN

1.2.2. Połączenie wszystkich Data Frame w jeden pogodowy

1.2.3. - Agregacja danych do postaci uniwersalnego DataFrame

```
Out[44]: array([17.])
```

1.2.4. PODSUMOWANIE PKT. 1.2. CAŁKOWITE OPADY

OPIS ZMIENNYCH

Zmienna	Opis
'PZ'	MIASTO ZAPISANE W SYMBOLEM
	PZ = Poznań
	LD = Łódź
'time'	DATA.GODZINA
'tp'	CAŁKOWITE OPADY / jednostka [m]

1.3. TABELLE INWERSJE - inwersja-pz

1.3.1. Import wszystkich plików do odpowiednich zmiennych

Unnamed: 0		time	isobaricInhPa	latitude	longitude	number	step	valid_time
0	0	2021-01-01 00:00:00	1000.0	52.5	17.0	0	0 days	2021-01-01 00:00:00
1	1	2021-01-01 00:00:00	925.0	52.5	17.0	0	0 days	2021-01-01 00:00:00

1.3.2. Łączymy wszystkie tabele do jednego DataFrame

1.3.3. Agregacja danych do postaci uniwersalnego datasetu.

		time	city	inversion_0/1
1005	2021-09-09 06:00:00		PZ	0
1006	2021-09-09 12:00:00		PZ	1
1007	2021-09-09 18:00:00		PZ	1
1008	2021-09-10 00:00:00		PZ	0
1009	2021-09-10 06:00:00		PZ	0

```
array(['PZ'], dtype=object)
array([0, 1])
```

1.3.4. PODSUMOWANIE PKT. 1.3. Inwersje

OPIS ZMIENNYCH

Zmienna	Opis
'PZ'	MIASTO ZAPISANE W SYMBOLEM (PZ = Poznań , LD = Łódź)
'time'	DATA GODZINA
'inverion_0/1'	inwersja_0 = NIE MA / inwerja_1 = JEST

1.4. Tabele Zanieczyszczeń Powietrza - data_pollution_

1.4.1. Import wszystkich plików do odpowiednich zmiennych

Unnamed: 0	Date_time	LdLodz_PM10	WpPozn_PM10	LdLodz_PM25	WpPozn_PM25
0	2021-01-01 01:00:00	44.0	NaN	28.0	NaN

1.4.2. Połączenie obu datasetów do jednego DataFrame

1.4.3. Agregacja danych do postaci uniwersalnego DataFrame

	time	PM10	PM25	NO2	CO	city
0	2021-01-01 06:00:00	NaN	NaN	13.9916	0.35462	PZ
1	2021-01-01 12:00:00	NaN	NaN	18.1778	0.35767	PZ

1.4.4. Podsumowanie dla Danych Zanieczyszczeń

OPIS ZMIENNYCH

Zmienna	Opis	Jednostka
PM10	(Particulate Matter 10) to pył zawieszony składający się z cząstek o średnicy aerodynamicznej mniejszej niż 10 mikrometrów (μm).	$\mu\text{g}/\text{m}^3$
PM25	PM2.5 to bardzo drobny pył zawieszony o średnicy poniżej 2,5 μm .	$\mu\text{g}/\text{m}^3$
NO2	NO ₂ to gaz należący do grupy tlenków azotu.	$\mu\text{g}/\text{m}^3$
CO	CO to bezbarwny i bezwonny gaz powstający przy niecałkowitym spalaniu paliw.	mg/m^3

1.5. Połączenie wszystkich danych do jednego DataFrame MAIN

DANE_POGODOWE + DANE_CAŁKOWITYCH_OPADÓW + INWERSJA => all_weather_df
 ALL_WEATHER + POLUTION => MAIN_DF

1.5.1 Walidacja main_df oraz weryfikacja struktury, statystyka opisowa

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5850 entries, 0 to 5849
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   time                  5850 non-null   datetime64[ns]
1   v_w                   5850 non-null   float64
2   t2m                   5850 non-null   float64
3   blh                   5850 non-null   float64
4   sp                    5850 non-null   float64
5   tcc                   5850 non-null   float64
6   tp                    5844 non-null   float64
7   inversion_0/1        5850 non-null   int64
8   PM10                  5611 non-null   float64
9   PM25                  5611 non-null   float64
10  NO2                   5674 non-null   float64
11  CO                    5767 non-null   float64
dtypes: datetime64[ns](1), float64(10), int64(1)
memory usage: 548.6 KB
None
```

=====

=====

	time	v_w	t2m	blh	sp
count	5850	5850.000000	5850.000000	5850.000000	5850.000000
mean	2023-01-01 08:59:37.846153984	3.579469	283.471655	568.535661	100504.209910
min	2021-01-01 00:00:00	0.060796	255.671300	11.653364	96769.060000
25%	2022-01-01 06:00:00	2.265287	276.826053	185.746673	99947.937500
50%	2023-01-01 06:00:00	3.306831	282.959100	399.582390	100550.875000
75%	2024-01-01 06:00:00	4.578002	289.857790	807.552315	101097.593750
max	2024-12-31 18:00:00	12.903320	308.316160	2955.042000	103377.810000
std	NaN	1.770486	8.435161	504.589010	932.558411

=====

=====

(5850, 12)

=====

=====

	time	v_w	t2m	blh	sp	tcc	tp	ir
0	2021-01-01 00:00:00	3.187178	270.71216	147.413560	99757.560	0.931488	4.768372e-07	
1	2021-01-01 06:00:00	3.497952	270.98218	250.487580	99785.560	1.000000	2.765655e-05	
2	2021-01-01 12:00:00	3.090875	271.01196	346.949220	99814.125	1.000000	1.859665e-05	
3	2021-01-01 18:00:00	2.620411	271.90990	175.696300	99937.690	0.994904	1.430511e-06	
4	2021-01-02 00:00:00	1.732178	273.76782	113.654526	100210.560	0.971130	9.536743e-07	
5	2021-01-02 06:00:00	1.491031	272.59230	77.243576	100417.060	0.790192	1.907349e-06	
6	2021-01-02 12:00:00	0.960483	273.81104	273.462650	100541.875	1.000000	0.000000e+00	
7	2021-01-02 18:00:00	2.182979	272.58154	271.882080	100690.810	0.980347	4.768372e-07	
8	2021-01-03 00:00:00	3.927681	272.70776	317.346680	100674.560	1.000000	2.384186e-06	
9	2021-01-03 06:00:00	5.433388	273.18190	395.399900	100526.810	1.000000	1.821518e-04	



2. Pierwsza Diegnostyka / EDA / Agregacja DataFrame

2.1. Sprawdzenie Duplikatów

Wniosek:

Dane pochodzą z profesjonalnego źródła, więc o ile na etapie importu i procesów przygotowania danych nie pojawiły się błędy, to nasz DataFrame nie powinien zawierać żadnych duplikatów.

Out [88]: 0

2.2. Sprawdzenie i naprawa brakujących danych NaN

Out [90]:

	count_nan	%_nan
PM10	239	4.09
PM25	239	4.09
NO2	176	3.01
CO	83	1.42
tp	6	0.10
time	0	0.00
v_w	0	0.00
t2m	0	0.00
blh	0	0.00
sp	0	0.00
tcc	0	0.00
inversion_0/1	0	0.00

2.3. EDA

2.3.1. Generujemy Raport EDA

2.3.2. Analiza Skośności rozkładów + transformacja zmiennych numerycznych

Wniosek:

Największa skośność rozkładu przypadana zmienna 'tp' są to opady, stąd uproszczeniem jest transformacja tej zmiennej na wartości binarne


- 0 dla braku opadów
- 1 dla zaobserwowanych opadów


Wnioski:

Dla zmiennych w kolumnach celu PM10, CO, PM10, PM25, NO2, oraz cechy 'blh', rozkłady są znacząco skośne konieczne będzie zastosowanie Transformacji Logarytmicznej przy tworzeniu modeli tego wymagających jak np LinearRegression.


Out[98]:


	features	skew
0	tp	9.151185
1	CO	4.290563
2	PM10	3.942233
3	PM25	3.076848
4	NO2	1.590106
5	blh	1.311941







Historam : blh







Historam : tcc









Historam : PM10




Historam : PM25



Historam : NO2






2.3.3. Analiza Outliery

Wnioski:

Nie usuwam żadnych outlierów, gdyż są to dane realne, zdobyte zgodnie ze wskazaniami prawidłowo działających stacji meteorologicznych. Każda wartość będąca poza zakresem IQR to rzeczywista obserwacja, więc usunięcie ich byłoby fałszowaniem danych.



2.3.4. Badanie korelacji cech numerycznych PERSONA

Korelacja Pearsona (r)

Definicja: Mierzy siłę i kierunek liniowej zależności między dwiema zmiennymi ilościowymi.

Wniosek : Z uwagi na wcześniejsza analiza czynników meteorologicznych mających wpływ na poziom jakości powietrza na danym obszarze, postanawiam nie usuwać, żadnych z wymienionych cech numerycznych.

Ale w badaniu skuteczności modeli może okazać się , że niektóre dane wymagają usunięcia

Out [108...

	PM10
blh	0.300624
inversion_0/1	0.278079
v_w	0.238196
t2m	0.224400
sp	0.163003
tp_0/1	0.125861
tcc	0.033921


2.3.5. Badanie korelacji cech kategoriycznych i numerycznych.

Cecha, Pearson, Spearman, ϕ_k (Phi_k) Typ danych, Tylko liczbowe (ciągłe), Liczbowe / Porządkowe, Mieszane (Liczby + Tekst) Rodzaj relacji, Tylko liniowa, Monotoniczna (niekoniecznie linia), "Dowolna (nawet ""zygzaki"")" Wrażliwość na outliery, Bardzo wysoka, Niska, Niska Kierunek (dodatni/ujemny), Tak, Tak, Nie (tylko siła związku) Wymagany rozkład normalny, Tak, Nie, Nie

```
interval columns not set, guessing: ['v_w', 't2m', 'blh', 'sp', 'tcc', 'inversion_0/1', 'PM10', 'PM25', 'NO2', 'CO', 'tp_0/1']
```

```
/opt/anaconda3/lib/python3.12/site-packages/phik/data_quality.py:59: UserWarning: The number of unique values of variable time is large: 5433. Are you sure this is not an interval variable? Analysis for pairs of variables including time can be slow.
  warnings.warn(
```

```
<>:15: SyntaxWarning: invalid escape sequence '\p'
<>:15: SyntaxWarning: invalid escape sequence '\p'
/var/folders/1_/28vylhx11cs54zyvgx55gyfw0000gn/T/ipykernel_91736/1165765018.py:15: SyntaxWarning: invalid escape sequence '\p'
  plt.title('Macierz Korelacji  $\phi_k$ ', fontsize=16)
```



2.3.6. Wnioski / Podsumowanie

1. Część dancyh cech zmiennych takie jak

- 'bhl' (wysokość warstwy granicznej) jest
- 'tp' (całkowite opady)

Prezentują dużą skośność rozkładu danych. Należy zastosować odpowiednie transformację dla modeli liniowych, numerycznych. 2. Analiza braków danych pokazuje, że najwięcej danych brakuje w zmiennych celu:

- PM10 = 239
- PM25 = 239
- NO2 = 176
- CO = 83
- tp = 6

3. Analiza Outlierów pokazuje duże extrema dla kilku danych meteorologicznych , są to jednak rzeczywiste pomiary , dla których należy

zachować wszystkie wartości. 3.1. Przy możliwości użycia redukcji wpływów ekstremów na działanie modeli, zostaną użyte odpowiednie parametry.

3. Transformacja danych

3.1. Feature engineering

3.2. Podział train test

Out[128...

	month	hour	day_of_week	is_night	is_weekend	season	v_w	
5378	September	00:00:00	Thursday	0	0	Autum	4.550661	2
1711	March	06:00:00	Friday	0	0	Spring	3.020459	2
2848	December	12:00:00	Tuesday	1	0	Winter	4.303393	:
704	June	00:00:00	Saturday	0	1	Summer	0.971361	2
3419	May	18:00:00	Thursday	1	0	Spring	1.665097	:
...	...	...	...	...	...	...	...	
4072	October	00:00:00	Sunday	0	1	Autum	5.519260	2
5581	October	18:00:00	Friday	1	0	Autum	2.911693	2
5625	November	18:00:00	Tuesday	1	0	Autum	1.345457	
5806	December	00:00:00	Saturday	0	1	Winter	4.786034	2
916	August	00:00:00	Wednesday	0	0	Summer	5.793679	2

4346 rows x 13 columns

3.3. Preprocessing dla Linear Regression

3.3.1. Standard Scaller

Out[132... ['v_w', 't2m', 'blh', 'tp_0/1', 'year', 'day']

3.3.2. Transformacja Logarytmiczna

```
Out[135... ['blh']
```

3.3.3. One hot encoding

```
Out[138... ['month', 'hour', 'day_of_week', 'is_night', 'is_weekend', 'season']
```

3.4. Pipeline Preprocessing

3.4.1. Linear Regression Pipeline

3.5. Transformacja

3.3.1. Transformacja Kolumn do Linear Regression

4. Budowanie Modeli Uczenia Maszynowego

4.0. Dummy Regresion

```
Out[147... ['PM10', 'PM25', 'N02', 'CO']
```

```
POLUTION: PM10 -> MAE=10.883 RMSE=16.167 R2=-0.001  
POLUTION: PM25 -> MAE=9.148 RMSE=13.376 R2=-0.001  
POLUTION: N02 -> MAE=10.123 RMSE=13.773 R2=-0.002  
POLUTION: CO -> MAE=0.112 RMSE=0.185 R2=-0.001
```

4.1. Linear Regression

4.1.1. Budowa modelu Linear Regression

Dla każdeko celu oddzielnie

Modele zostały wytrenowane.

4.1.2. Predykcja

Predykcje zostały wykonane

4.1.3. Metryki jakości modelu

- MAE - średni błąd bezwzględny

- RMSE - pierwiastek błędu średniokwadratowego
- R2 - procent wyjaśnienia wariancji

Out [156...

	MAE	RMSE	R2
PM10	8.753	13.101	0.343
PM25	6.979	10.356	0.400
NO2	7.202	10.057	0.466
CO	0.092	0.150	0.342



PM10: CV $R^2 = 0.188 \pm 0.107$

PM25: CV $R^2 = 0.339 \pm 0.064$

NO2: CV $R^2 = 0.141 \pm 0.166$

CO: CV $R^2 = 0.264 \pm 0.050$

4.1.4 Wizualizacja wyników



4.2. CatBoost

4.2.1. Budowa Modelu CatBoost

4.2.2. Trenowanie modelu CatBoost

=====

Trenowanie modelu dla: PM10

=====

0:	learn: 0.0223334	test: 0.0223274	best: 0.0223274 (0)	tota
l: 63.5ms	remaining: 1m 3s			
100:	learn: 0.5285650	test: 0.4349972	best: 0.4349972 (100)	tota
l: 1.7s	remaining: 15.2s			
200:	learn: 0.6417619	test: 0.4863279	best: 0.4863279 (200)	tota
l: 3.75s	remaining: 14.9s			
300:	learn: 0.7002910	test: 0.5059279	best: 0.5059279 (300)	tota
l: 6.21s	remaining: 14.4s			
400:	learn: 0.7438690	test: 0.5206488	best: 0.5207896 (399)	tota
l: 9.4s	remaining: 14s			
500:	learn: 0.7774428	test: 0.5308403	best: 0.5308403 (500)	tota
l: 11.7s	remaining: 11.7s			
600:	learn: 0.8051676	test: 0.5373499	best: 0.5374245 (596)	tota
l: 13.8s	remaining: 9.19s			
700:	learn: 0.8290351	test: 0.5442793	best: 0.5442793 (700)	tota
l: 16.4s	remaining: 7.01s			
800:	learn: 0.8462975	test: 0.5489316	best: 0.5489585 (798)	tota
l: 19.6s	remaining: 4.87s			
900:	learn: 0.8679558	test: 0.5569654	best: 0.5569654 (900)	tota
l: 22.7s	remaining: 2.49s			
999:	learn: 0.8851904	test: 0.5630549	best: 0.5630549 (999)	tota
l: 24.7s	remaining: 0us			

bestTest = 0.5630548567

bestIteration = 999

=====

Trenowanie modelu dla: PM25

=====

0:	learn: 0.0343033	test: 0.0315514	best: 0.0315514 (0)	tota
l: 3.51ms	remaining: 3.51s			
100:	learn: 0.6507226	test: 0.4954385	best: 0.4954385 (100)	tota
l: 1.87s	remaining: 16.7s			
200:	learn: 0.7616218	test: 0.5449518	best: 0.5449518 (200)	tota
l: 3.85s	remaining: 15.3s			
300:	learn: 0.8123269	test: 0.5669480	best: 0.5669480 (300)	tota
l: 5.56s	remaining: 12.9s			
400:	learn: 0.8441886	test: 0.5800160	best: 0.5800160 (400)	tota
l: 7.65s	remaining: 11.4s			
500:	learn: 0.8698027	test: 0.5873036	best: 0.5873036 (500)	tota
l: 9.61s	remaining: 9.57s			
600:	learn: 0.8886012	test: 0.5925277	best: 0.5925277 (600)	tota
l: 11.3s	remaining: 7.47s			
700:	learn: 0.9048495	test: 0.5956854	best: 0.5956854 (700)	tota
l: 12.9s	remaining: 5.51s			
800:	learn: 0.9180424	test: 0.5979341	best: 0.5980788 (797)	tota
l: 14.5s	remaining: 3.6s			
900:	learn: 0.9280393	test: 0.6002527	best: 0.6002819 (898)	tota
l: 16.2s	remaining: 1.77s			
999:	learn: 0.9376369	test: 0.6015186	best: 0.6016468 (984)	tota
l: 17.7s	remaining: 0us			

bestTest = 0.6016467537
bestIteration = 984

Shrink model to first 985 iterations.

=====

Trenowanie modelu dla: N02

=====

0:	learn: 0.0388165	test: 0.0314843	best: 0.0314843 (0)	tota
l: 35.8ms	remaining: 35.8s			
100:	learn: 0.7310784	test: 0.6151122	best: 0.6151122 (100)	tota
l: 1.79s	remaining: 15.9s			
200:	learn: 0.8034336	test: 0.6515692	best: 0.6515692 (200)	tota
l: 3.58s	remaining: 14.2s			
300:	learn: 0.8377107	test: 0.6618470	best: 0.6618470 (300)	tota
l: 5.43s	remaining: 12.6s			
400:	learn: 0.8609307	test: 0.6678819	best: 0.6679304 (397)	tota
l: 8.32s	remaining: 12.4s			
500:	learn: 0.8790570	test: 0.6714284	best: 0.6714880 (499)	tota
l: 11.2s	remaining: 11.2s			
600:	learn: 0.8956937	test: 0.6745444	best: 0.6746141 (598)	tota
l: 13.6s	remaining: 9.01s			
700:	learn: 0.9090491	test: 0.6766813	best: 0.6766813 (700)	tota
l: 15.5s	remaining: 6.63s			
800:	learn: 0.9215371	test: 0.6779834	best: 0.6783280 (785)	tota
l: 17.6s	remaining: 4.36s			

Stopped by overfitting detector (50 iterations wait)

bestTest = 0.6783280047
bestIteration = 785

Shrink model to first 786 iterations.

=====

Trenowanie modelu dla: C0

=====

0:	learn: 0.0284505	test: 0.0252593	best: 0.0252593 (0)	tota
l: 16.3ms	remaining: 16.3s			
100:	learn: 0.6559427	test: 0.5128718	best: 0.5128718 (100)	tota
l: 1.46s	remaining: 13s			
200:	learn: 0.7711213	test: 0.5568878	best: 0.5568878 (200)	tota
l: 3.24s	remaining: 12.9s			
300:	learn: 0.8292536	test: 0.5763012	best: 0.5763012 (300)	tota
l: 5.52s	remaining: 12.8s			
400:	learn: 0.8582297	test: 0.5838354	best: 0.5838354 (400)	tota
l: 7.42s	remaining: 11.1s			
500:	learn: 0.8792150	test: 0.5902108	best: 0.5903635 (496)	tota
l: 9.57s	remaining: 9.53s			
600:	learn: 0.8963952	test: 0.5929076	best: 0.5929222 (593)	tota
l: 11.3s	remaining: 7.51s			
700:	learn: 0.9095394	test: 0.5943185	best: 0.5944619 (692)	tota
l: 12.8s	remaining: 5.44s			

Stopped by overfitting detector (50 iterations wait)

bestTest = 0.5944619223
bestIteration = 692

Shrink model to first 693 iterations.

4.2.3. Predykcja


PM10: wykonano 1087 predykcji
PM25: wykonano 1087 predykcji
NO2: wykonano 1087 predykcji
CO: wykonano 1087 predykcji

4.2.4. Metryki dla GB

Out [169...

	MAE	RMSE	R2
PM10	6.993173	10.683754	0.563055
PM25	5.583382	8.437219	0.601647
NO2	5.232095	7.804223	0.678328
CO	0.065410	0.117826	0.594462

4.2.5. Wizualizację metryk



5. Wnioski

Celem projektu było porównanie skuteczności modeli **Linear Regression** oraz **CatBoost Regressor** w prognozowaniu stężeń zanieczyszczeń powietrza (**PM10, PM2.5, NO₂** oraz **CO**) na podstawie danych meteorologicznych.

Przeprowadzona analiza wykazała, że model **CatBoost** osiągnął lepsze wyniki dla wszystkich analizowanych zmiennych. Potwierdzają to wyższe wartości współczynnika determinacji **R²** oraz niższe wartości błędów **MAE** i **RMSE** w porównaniu z regresją liniową.

Najlepsze rezultaty uzyskano dla predykcji stężenia **NO₂**, gdzie model CatBoost osiągnął wartość **R² = 0.678**, natomiast największą poprawę względem regresji liniowej zaobserwowano dla zmiennych **CO** oraz **PM10**.

Uzyskane wyniki wskazują, że zależności pomiędzy warunkami meteorologicznymi a poziomem zanieczyszczeń mają charakter nieliniowy, dlatego model CatBoost, oparty na metodzie gradient boosting, skuteczniej odwzorowuje występujące w danych zależności niż klasyczna regresja liniowa.

Na podstawie przeprowadzonych eksperymentów można stwierdzić, że **CatBoost Regressor stanowi bardziej efektywne narzędzie do prognozowania jakości powietrza na podstawie danych meteorologicznych**, zapewniając wyższą dokładność i lepszą zdolność generalizacji na danych testowych.

